Open Data Science
Курс «LLM: От понимания к продукту»

ИИ-агент для ВНДО (Внутренние нормативные документы организации)

Слоган: Интеллектуальный поиск релевантной информации ВНД, как основа оптимизации производственной деятельности.

Команда:

Название команды: ОЭКИИ

Состав команды:

○ Кантемиров Роман (Product manage, AI Engineer, MLOps)

○ +79088002878, r_kantemirov@mail.ru ○

Ссылка на репозиторий/артефакты проекта:

https://github.com/kantemirovrs/ai-agent-vndo.git

Цели и задачи

- Цель проекта – построение ИС ВНД на основе генеративной модели (LLM), источником информации которой является совокупность имеющихся в организации внутренней нормативной документации (ВНД), с целью оптимизации процессов поиска, обобщения, анализа, представления целевой информации.
- Задачи проекта:
  1. Анализ целесообразности и экономической эффективности реализации проекта, расчёт объективных и субъективных затрат, возможных рисков.
  2. Предобработка имеющихся ВНД (парсинг, сегментация, векторизация нормативной базы).
  3. Построение генеративной модели на основе RAG (построение инфраструктуры для on-premise реализации, векторного хранилища, интеграция с LLM, разработка пользовательского интерфейса).
  4. Подбор метрик эффективности, на их основе оценка качества и оптимизация модели .

Проблема

Проект направлен на решение проблемы оперативного поиска, анализа и представления релевантной информации ВНД, на основании пользовательского запроса, с учётом её исторической актуальности.
Реализация проекта должна минимизировать время ознакомления, адаптации новых сотрудников с правилами, регламентами, инструкциями и нормами поведения внутри компании, упростить их включение в производственные и бизнес процессы.
На текущий момент времени, все сотрудники компании, так или иначе используют в своей профессиональной деятельности положения ВНД. Для поиска целевой информации, они должны знать метаданные каждого документа, место его расположения, обладать соответствующими правами доступа. При этом, информация может содержаться в нескольких источниках, что требует от пользователя знания всей номенклатуры ВНД. Таким образом, отсутствие семантического подбора информации, в значительной степени усложняет процесс поиска, извлечения, анализа данных, может стать причиной всевозможных пользовательских ошибок и, как следствие этого, материального либо репутационного ущерба.

Масштаб проблемы

- Примерно 60% персонала работают с ВНД на постоянной основе, остальные 40% сотрудников взаимодействуют с ВНДО эпизодически (ознакомление с приказами, инструкциями, распоряжениями и т.д.). Как правило, из-за большого объёма нормативной документации, ознакомление с содержанием самих ВНД носит формальный, опосредованный характер. Кроме того, в силу физиологических особенностей человека, держать в памяти все детали огромного разнообразия нормативной документации не представляется возможным.
- Следует отметить, что практически все аспекты производственной деятельности, строго регламентированы внутренними нормативными документами, их нарушение (по незнанию, халатности) может привести к административным, дисциплинарным взысканиям, материальному либо репутационному ущербу.
- Ежегодно, около 30% номенклатуры ВНД претерпевают изменения, дополнения, часть из них утрачивают свою юридическую силу. Это требует от сотрудников знания не только содержания самих ВНД, но и контроля актуальности их редакции в заданный временной период.

Решение

Реализация проекта предполагает создание корпоративного on-premise ресурса, на котором пользователь смог бы самостоятельно, сформулировав свой запрос к ИИ-агенту, получить релевантную информацию из ВНДО, с указанием ссылок на документы, которые легли в основу представленного ответа, в соответствии с исторической актуальностью нормативной базы. Проект предусматривает использование open source модели LLM, стека технологий RAG и векторных СУБД. В связи с со спецификой проекта, его задач, объективных и субъективных составляющих, использование LLM представляется наиболее оптимальным решением данной задачи. Где задача LLM – это генерация ответа на пользовательский запрос, построенный исключительно на контексте ВНД.

Технический аспект

При реализации проекта, предполагается использование модели с открытым исходным кодом из семейства Qwen3 (Qwen3-30B-A3B-Instruct-2507). Она предлагает оптимальный баланс эффективности и функциональности. Большое контекстное окно делает ее идеальным решением для приложений RAG, когда необходимо обрабатывать огромные коллекции документов, сохраняя при этом экономическую эффективность.

В качестве пользовательского интерфейса для взаимодействия с LLM целесообразно использовать open-source решение с возможностью локальной инсталляции - Open Web UI.

Реализация Retrieval-этапа предусматривает использование легковесных эмбеддинг-моделей таких как Intfloat/multilingual-e5-base.

Для хранения векторных представлений нормативной документации планируется задействовать векторную БД Qdrant.

Пользовательский сценарий

1. Пользователь, через веб приложение инициирует запрос ИИ-Агенту.
2. ИИ-агент преобразует запрос в векторное представление и выполняет поиск релевантных фрагментов информации в векторной БД.
3. Найденные фрагменты, вместе с исходным запросом объединяются в единый промпт генеративной модели.
4. LLM формирует ответ, ссылаясь на предоставленные фрагменты и источники, визуализирует его в пользовательском окне.
5. Пользователь может задать утоняющий вопрос, перейти к первоисточникам, запросить дополнительную информацию, оценить работу ИИ-агента.

Пример:

- Сотрудник, через веб приложение, отправляет запрос: «Кто сейчас утверждает номенклатуру дел в компании?»
- Ответ ИИ агента: «Номенклатура дел Общества подписывается директором по персоналу, начальником отдела документационного обеспечения, согласовывается с Экспертной комиссией Общества, утверждается приказом Генерального директора.»
- Источник: Приказ № ВД-231 от 01.09.2025 «Об утверждении Методики организации архивного хранения.» п.п.7.2

Реализация

- Решение предусматривает создание ИИ-агента, на основе LLM-модели с RAG системой в закрытом контуре инфраструктуры компании.
- Текущий статус – идея, проект представлен в виде презентации. Ведётся проработка концепций, подбор технологического стека, изучаются возможные объективные и субъективные риски, стоимость реализации.
- С учётом специфики проекта, наличия достаточного количества необходимых данных (ВНД), подготовка и проведение пилота на одном тематическом кластере ВНД является приоритетными.

Стоимость решения

В связи с отсутствием готового решения на рынке ПО РФ, высокими требованиями ИБ, наличием в контексте ВНД конфиденциальной информации, самостоятельная разработка ИИ-агента является приоритетной.

Для этого потребуется создание необходимой инфраструктуры, формирование компетентного комьюнити компании.

В зависимости от масштаба реализации, цена базовых RAG-решений варьируется от 25 до 30 млн. руб.

В стоимость входят:

1. Затраты на анализ и проектирование: оценка данных, сценариев использования, выбор архитектуры.
2. Разработка ПО: Написание кода пайплайнов индексации, поиска и генерации, интеграции с существующими ИС компании.
3. Операционные расходы, регулярные затраты на поддержку и использование системы.
4. Стоимость аппаратного обеспечения (GPU-сервера, коммутационное оборудование и т.д.)

Что будет, если не делать проект?

С учётом ежегодного расширения номенклатуры ВНД компании, высокого кадрового оборота, требованиями современного делопроизводства, потребность в ИИ-агентах, обеспечивающих быстрый и качественный, семантический поиск на всём многообразии ВНД, будет только возрастать.

Без реализации данного проекта, поиск, анализ, обработка необходимой информации будет по-прежнему отнимать у сотрудников много времени, а следовательно, производительность труда в этом аспекте будет оставаться на низком уровне.

Использование ВНД требует от пользователя постоянной актуализации знаний, которая зачастую, сопряжена с повторным ознакомлением с содержанием одного или нескольких нормативных документов. Тогда как ИИ-агент способен максимально быстро отобрать релевантные данные и сгенерировать ответ на конкретный пользовательский запрос.

В силу человеческого фактора, высока вероятность использования не релевантных данных, которые, в свою очередь могут привести к существенным материальным либо репутационным издержкам.

Безопасность и ограничения

К рискам и ограничениям можно отнести следующие аспекты :

1. Несоответствие инфраструктуры требованиям проекта, сложности интеграции с имеющимися корпоративными системами.

Решение: Перераспределение аппаратных ресурсов инфраструктуры, выбор более легковесных моделей.

2. Запрет на реализацию проекта со стороны ИБ.

Решение: дополнительный мониторинг сетевой активности, применение политик безопасности AD/GPO, использование изолированного контура для тестирования модели, использование контейнеризации.

3. Векторизация большого числа ВНД.

Решение: разделение ВНД по тематическим кластерам, поэтапная векторизация.

Спасибо за внимание!